

ĐỀ CƯƠNG NGHIÊN CỨU

Học phần IT3940 – Project 3

NGHIÊN CỨU THỰC NGHIỆM VỀ CÁC CÁCH KHAI THÁC ĐỘ TIN CẬY CỦA MÔ HÌNH GIÁO VIÊN TRONG KNOWLEDGE DISTILLATION

An Empirical Study of Teacher Confidence Utilization in Knowledge Distillation

Người thực hiện: Võ Hữu Trí Dũng

Giảng viên: Tạ Duy Hoàng

Hướng nghiên cứu: Knowledge Distillation / Efficient Deep Learning

Tóm tắt đề xuất

Knowledge Distillation (KD) huấn luyện một mô hình *student* nhỏ bằng cả nhãn thật và phân phối dự đoán của một mô hình *teacher* lớn hơn. Trong KD cơ bản, mọi mẫu thường nhận cùng trọng số distillation, cùng tỷ lệ kết hợp CE-KD và cùng temperature. Giả định đồng nhất này bỏ qua việc teacher không đáng tin cậy và không giàu thông tin như nhau trên mọi mẫu. Đề tài tập trung vào câu hỏi: *Teacher confidence nên được đo bằng tín hiệu nào, được sử dụng tại vị trí nào trong KD, và nên ưu tiên mẫu confidence cao hay uncertainty cao?*

Nghiên cứu được định vị là một **controlled empirical study**. Thiết kế tách ba quyết định độc lập: *confidence signal*, *intervention mechanism* và *priority orientation*. Các thí nghiệm sử dụng CIFAR-100 với cặp WRN-40-2 → WRN-16-2, teacher cố định và cùng một protocol huấn luyện. Mục tiêu là tạo ra bằng chứng nhỏ gọn, có kiểm soát và dễ tái lập về cách sử dụng teacher confidence trong logit-based KD.

1. Bối cảnh và động lực

Phân phối mềm của teacher chứa thông tin về quan hệ giữa các lớp cạnh tranh, thường được gọi là *dark knowledge* [1]. Tuy nhiên, confidence thay đổi đáng kể theo từng mẫu và không nhất thiết phản ánh xác suất đúng nếu mô hình chưa được hiệu chỉnh tốt [2]. Hai trực giác đối lập vì thế cùng hợp lý: (i) mẫu confidence cao có thể cung cấp supervision đáng tin hơn; (ii) mẫu uncertainty cao có thể nằm gần biên quyết định và biểu lộ rõ hơn quan hệ giữa các lớp phụ.

Reliability và informativeness không nhất thiết trùng nhau. Các nghiên cứu trước đã khảo sát soft label có trọng số theo mẫu, confidence-aware weighting và temperature động [5, 7, 6]; tuy nhiên, khi nhiều quyết định thay đổi đồng thời, khó xác định cải thiện đến từ việc *xếp hạng đúng mẫu* hay chỉ từ thay đổi phân bố gradient. Đề tài giải quyết khoảng trống thực nghiệm này bằng cách thay đổi một thành phần tại một thời điểm và dùng phép kiểm soát hoán vị score.

2. Mục tiêu và câu hỏi nghiên cứu

Mục tiêu tổng quát là xây dựng một protocol thực nghiệm có kiểm soát để đánh giá các cách khai thác confidence của một teacher trong logit-based KD trên bài toán phân loại ảnh quy mô nhỏ.

- **RQ1:** Tín hiệu confidence nào hữu ích nhất cho KD?
- **RQ2:** Confidence nên điều khiển trọng số KD, tỷ lệ CE-KD hay temperature?
- **RQ3:** Nên ưu tiên mẫu confidence cao hay mẫu uncertainty cao?
- **RQ4:** Lợi ích có đến từ quan hệ giữa score và đúng mẫu, hay chỉ từ phân bố trọng số và gradient scale?

3. Thiết lập Knowledge Distillation nền

Với mẫu (x_i, y_i) , teacher và student tạo logits z_i^T, z_i^S . Tại temperature τ ,

$$q_i^M(\tau) = \text{softmax}(z_i^M / \tau), \quad M \in \{T, S\}, \quad \mathcal{L}_i^{\text{KD}}(\tau) = \tau^2 \text{KL}(q_i^T(\tau) \| q_i^S(\tau)). \quad (1)$$

Vanilla KD kết hợp supervision từ nhãn thật và teacher:

$$\mathcal{L}_i = (1 - \lambda_0) \mathcal{L}_i^{\text{CE}} + \lambda_0 \mathcal{L}_i^{\text{KD}}(\tau_0). \quad (2)$$


Trong đó λ_0 cân bằng CE-KD, còn τ_0 quyết định độ mềm của soft target. Khung tổng quát được khảo sát là

$$\mathcal{L} = \frac{1}{B} \sum_{i=1}^B [(1 - \lambda_i) \mathcal{L}_i^{\text{CE}} + \lambda_i w_i \mathcal{L}_i^{\text{KD}}(\tau_i)]. \quad (3)$$

Trong mỗi thí nghiệm chính, chỉ một trong ba đại lượng w_i, λ_i, τ_i thay đổi theo confidence; hai đại lượng còn lại được giữ ở giá trị vanilla KD.

4. Phương pháp: không gian nghiên cứu ba trục

Mỗi cấu hình là tích của ba quyết định độc lập:



Hình 1: Luồng khái niệm của một cấu hình confidence-aware KD.

4.1. Trục 1 – Confidence signal

Đặt $p_i^T = \text{softmax}(z_i^T)$ tại temperature 1 và C là số lớp. Bốn score được khảo sát gồm:

$$\begin{aligned} c_i^{\text{MCP}} &= \max_k p_{i,k}^T, & c_i^{\text{ENT}} &= 1 - \frac{H(p_i^T)}{\log C}, & (H(p_i^T) &= -\sum_k p_{i,k}^T \log p_{i,k}^T) \\ c_i^{\text{MAR}} &= p_{i,(1)}^T - p_{i,(2)}^T, & c_i^{\text{GT}} &= p_{i,y_i}^T. \end{aligned}$$

MCP đo độ chắc chắn của top-1; entropy confidence đo độ tập trung của toàn phân phối; margin đo độ tách biệt giữa hai lớp cạnh tranh nhất; còn ground-truth probability đo mức teacher ủng hộ nhãn đúng. Ba score đầu không dùng nhãn, trong khi GT là label-aware và chỉ dùng lúc huấn luyện.

Để so sánh công bằng, mỗi score được đổi thành percentile rank trên tập huấn luyện:

$$r_i = F_c(c_i) \in [0, 1], \quad (4)$$

với F_c là empirical CDF (dùng mid-rank khi có giá trị bằng nhau). Nhờ đó, các score có cùng thang và phân bố biên; khác biệt chủ yếu nằm ở cách chúng xếp hạng mẫu thay vì biên độ số học.

4.2. Trục 2 – Intervention mechanism

Với một priority orientation đã chọn, ký hiệu $s_i \in [0, 1]$ là *priority score*: s_i càng cao thì mẫu i nhận mức can thiệp càng mạnh. Đặt thêm

$$a_i = 2s_i - 1 \in [-1, 1]$$

là phiên bản đối xứng quanh 0, thuận tiện cho các phép điều chỉnh tăng hoặc giảm so với giá trị vanilla. Cách xây dựng s_i và a_i từ percentile rank r_i cho hai orientation được trình bày ở Mục 4.3.

A. Sample weighting. Giữ $\lambda_i = \lambda_0$, $\tau_i = \tau_0$ và chỉ thay đổi w_i :

$$\mathcal{L}_i = (1 - \lambda_0)\mathcal{L}_i^{\text{CE}} + \lambda_0 w_i \mathcal{L}_i^{\text{KD}}(\tau_0), \quad \tilde{w}_i = (\epsilon + s_i)^\gamma, \quad w_i = \frac{\tilde{w}_i}{\frac{1}{B} \sum_j \tilde{w}_j}.$$

Ở đây, $\epsilon > 0$ là hằng số nhỏ để tránh trọng số bằng 0, $\gamma \geq 0$ điều khiển độ tương phản giữa các trọng số, và B là kích thước mini-batch. Phép chuẩn hóa bảo đảm $B^{-1} \sum_i w_i = 1$, giữ quy mô trung bình của KD loss và tập trung câu hỏi vào *mẫu nào nên đóng góp gradient KD lớn hơn*.

B. Adaptive CE–KD mixing. Giữ $w_i = 1$, $\tau_i = \tau_0$ và đặt

$$\mathcal{L}_i = (1 - \lambda_i)\mathcal{L}_i^{\text{CE}} + \lambda_i \mathcal{L}_i^{\text{KD}}(\tau_0), \quad \lambda_i = \text{clip}(\lambda_0 + \delta a_i, \lambda_{\min}, \lambda_{\max}).$$

$\delta \geq 0$ điều khiển độ mạnh của phép điều chỉnh; $\lambda_{\min}$ và $\lambda_{\max}$ giới hạn tỷ lệ KD trong miền hợp lệ. λ_i cao nghĩa là tin teacher nhiều hơn, còn λ_i thấp chuyển trọng tâm về nhãn thật. Cơ chế này kiểm tra *trên mẫu nào nên ưu tiên teacher supervision*.

C. Adaptive temperature. Giữ $w_i = 1$, $\lambda_i = \lambda_0$ và đặt

$$\mathcal{L}_i = (1 - \lambda_0)\mathcal{L}_i^{\text{CE}} + \lambda_0 \mathcal{L}_i^{\text{KD}}(\tau_i), \quad \tau_i = \text{clip}(\tau_0 e^{\beta a_i}, \tau_{\min}, \tau_{\max}).$$

$\beta \geq 0$ điều khiển độ mạnh của phép thích nghi, còn $\tau_{\min}$ và $\tau_{\max}$ giới hạn miền temperature. Temperature cao tạo phân phối mềm hơn và làm lộ quan hệ giữa các lớp phụ; cơ chế này kiểm tra *mẫu nào nên được làm mềm mạnh hơn để khai thác dark knowledge*.

4.3. Trục 3 – Priority orientation

Sau chuẩn hóa, r_i cao nghĩa là teacher confidence cao. Hai orientation đối xứng được định nghĩa bởi

$$s_i^{\text{conf}} = r_i, \quad s_i^{\text{unc}} = 1 - r_i, \quad a_i^{\text{conf}} = 2r_i - 1, \quad a_i^{\text{unc}} = 1 - 2r_i = -a_i^{\text{conf}}. \quad (5)$$

Trong mỗi thí nghiệm, cặp (s_i, a_i) tương ứng với orientation được chọn sẽ được thay vào các công thức ở Mục 4.2. **Confidence emphasis** tăng can thiệp cho mẫu confidence cao, dựa trên trực giác reliability. **Uncertainty emphasis** tăng can thiệp cho mẫu confidence thấp, dựa trên trực giác informativeness. Hai hướng cần được kiểm tra đối xứng: confidence cao có thể đáng tin nhưng ít dark knowledge; uncertainty cao có thể giàu quan hệ lớp nhưng cũng có thể phản ánh lỗi hoặc sự bối rối của teacher.

Bảng 1: Ý nghĩa của hai priority orientation trong từng cơ chế.

Mechanism	Confidence emphasis	Uncertainty emphasis
Sample weighting	Tăng KD gradient cho confident samples	Tăng KD gradient cho uncertain samples
Adaptive mixing	Tin teacher nhiều hơn khi teacher confident	Tin teacher nhiều hơn trên uncertain samples
Adaptive temperature	Làm mềm mạnh confident targets	Làm mềm mạnh uncertain targets

5. Thiết lập thực nghiệm chính

Bảng 2: Thiết lập thực nghiệm được giữ cố định giữa các phương pháp.

Thành phần	Lựa chọn
Dataset	CIFAR-100: 100 lớp, ảnh 32×32 ; đủ nhỏ cho nhiều ablation nhưng vẫn là benchmark KD phổ biến [4].
Teacher–student	WRN-40-2 $\rightarrow$ WRN-16-2; cùng họ Wide Residual Network để giảm nhiễu do khác biệt kiến trúc [3].
Baselines	Student CE-only; vanilla KD; ...
Phạm vi	Single-teacher, logit-based KD; ưu tiên phân tích cơ chế thay vì scale hay accuracy tuyệt đối.

Quy trình gồm: (1) huấn luyện hoặc sử dụng một teacher checkpoint cố định; (2) huấn luyện CE-only student và vanilla KD; (3) chạy các biến thể confidence-aware theo chiến lược sàng lọc.

6. Thiết kế đánh giá

Chỉ số chính là Top-1 accuracy. Để giải thích cơ chế thay vì chỉ so sánh một con số tổng, nghiên cứu thực hiện so sánh:

- kết quả theo bốn quartile của teacher confidence;
- tách các mẫu teacher dự đoán đúng và sai;
- tỷ lệ student lặp lại lỗi top-1 của teacher;
- so sánh score thật với **score permutation**.

Trong permutation control, confidence rank được hoán vị giữa các mẫu nhưng giữ nguyên phân bố score và mapping can thiệp. Nếu score thật tốt hơn score hoán vị, lợi ích có khả năng đến từ việc xác định đúng mẫu cần ưu tiên. Nếu hai kết quả tương tự, gain có thể chủ yếu do gradient scaling hoặc regularization. Calibration chỉ được xem như robustness ablation tùy chọn, không phải mục tiêu đánh giá chính.

7. Kết quả kỳ vọng và đóng góp

Đề tài không đặt mục tiêu công bố một thuật toán mới hay đạt SOTA. Các đóng góp kỳ vọng gồm:

1. một cách tổ chức rõ ràng confidence-aware KD theo ba trục: signal, mechanism và orientation;
2. một nghiên cứu có kiểm soát tách riêng ảnh hưởng của từng thành phần;
3. bằng chứng về signal nào hữu ích, confidence nên tác động tại đâu, và reliability hay informativeness phù hợp hơn với từng mechanism;
4. hướng dẫn thực hành cho logit-based KD trong bối cảnh phân loại ảnh nhỏ và tài nguyên hạn chế.

Negative result vẫn có giá trị: nếu không cấu hình nào cải thiện vanilla KD ổn định, kết quả sẽ chỉ ra giới hạn của việc dùng teacher confidence như đại diện cho giá trị từng mẫu.

8. Kết luận

Đề tài đặt một câu hỏi hẹp nhưng nền tảng: khi độ tin cậy và giá trị thông tin của teacher thay đổi theo từng mẫu, confidence nên được đo và sử dụng như thế nào trong KD? Thiết kế ba trục phân biệt rõ tín hiệu đo, vị trí can thiệp và ưu tiên reliability hay informativeness. Với CIFAR-100 và WRN-40-2 $\rightarrow$ WRN-16-2, nghiên cứu có chi phí thấp, dễ tái lập và khả thi trong phạm vi Project 3, đồng thời đủ chặt chẽ để rút ra kết luận có căn cứ thay vì chỉ báo cáo một biến thể đạt accuracy cao hơn.

Tài liệu

- [1] G. Hinton, O. Vinyals, and J. Dean, “Distilling the Knowledge in a Neural Network,” *NIPS Deep Learning and Representation Learning Workshop*, 2015.
- [2] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, “On Calibration of Modern Neural Networks,” *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70, pp. 1321–1330, 2017.
- [3] S. Zagoruyko and N. Komodakis, “Wide Residual Networks,” *Proceedings of the British Machine Vision Conference (BMVC)*, 2016.
- [4] A. Krizhevsky, “Learning Multiple Layers of Features from Tiny Images,” Technical Report, University of Toronto, 2009.
- [5] H. Zhou, L. Song, J. Chen, Y. Zhou, G. Wang, J. Yuan, and Q. Zhang, “Rethinking Soft Labels for Knowledge Distillation: A Bias–Variance Tradeoff Perspective,” *International Conference on Learning Representations (ICLR)*, 2021.
- [6] Z. Li, X. Li, L. Yang, B. Zhao, R. Song, L. Luo, J. Li, and J. Yang, “Curriculum Temperature for Knowledge Distillation,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, no. 2, pp. 1504–1512, 2023.
- [7] H. Zhang, D. Chen, and C. Wang, “Confidence-Aware Multi-Teacher Knowledge Distillation,” *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2022.